Obtención y Preparación de Datos

Clase 04

Breve Introducción a Machine Learning

Dr. Ramón Caraballo
SECIU Red Académica Uruguaya
UDELAR

Objetivos

- Importar datos desde archivos de texto, excel, json, etc
- Limpieza básica de Datos, reemplazo, imputacion de datos etc.
- Análisis Exploratorio de Datos
- Estadística Básica

Importando Datos con Numpy

texto plano (CSV, TSV, etc)

numpy.loadtxt(*fname*, *dtype=<class 'float'>*, *comments='#'*, *delimiter=None*, *converters=None*, *skiprows=0*, *usecols=None*, *unpack=False*, *ndmin=0*, *encoding=None*, *max_rows=None*, ***, *quotechar=None*, *like=None*)

```
In [1]: import numpy as np

In [2]: filename = 'MNIST_header.txt'

In [3]: data = np.loadtxt(filename, delimiter=',',
skiprows=1)

In [4]: print(data)
[[   0.    0.    0.    0.    0.]
 [  86.  250.  254.  254.  254.]
 [   0.    0.    0.    9.  254.]
 ...,
 [   0.    0.    0.    0.    0.]
 [   0.    0.    0.    0.    0.]
 [   0.    0.    0.    0.    0.]]
```

https://numpy.org/doc/stable/user/index.html

Los datos deben ser del mismo tipo!!

Importando Datos con Pandas

Datos de diferente tipo

```
In [1]: import pandas as pd

In [2]: filename = 'winequality-red.csv'

In [3]: data = pd.read_csv(filename)

In [4]: data.head()
Out[4]:
   volatile acidity  citric acid  residual sugar
0              0.70         0.00             1.9
1              0.88         0.00             2.6
2              0.76         0.04             2.3
3              0.28         0.56             1.9
4              0.70         0.00             1.9

In [5]: data_array = data.values
```

https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html

Lo que necesita un científico de datos

- **Estructuras de datos bidimensionales etiquetadas**
- **Columnas de tipos potencialmente diferentes**
- **Manipular, segmentar, remodelar, agrupar, unir, fusionar**
- **Realizar estadísticas**
- **Trabajar con datos de series temporales**
- **Importar archivos planos de forma sencilla**
- **Importar archivos planos con problemas como comentarios y valores faltantes**

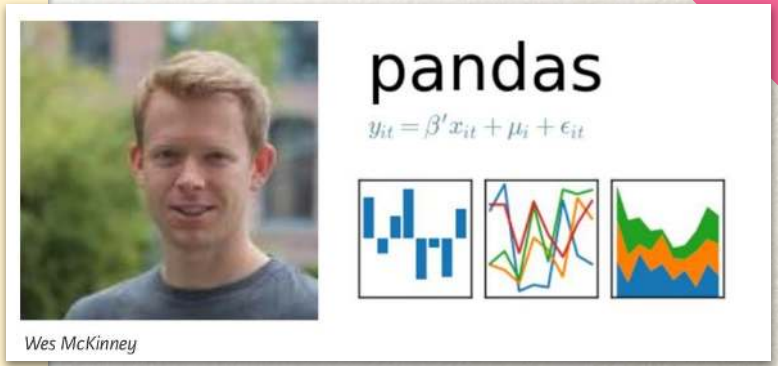

Python DataFrame = R Dataframe!!

- Estándares y mejores prácticas para usar pandas

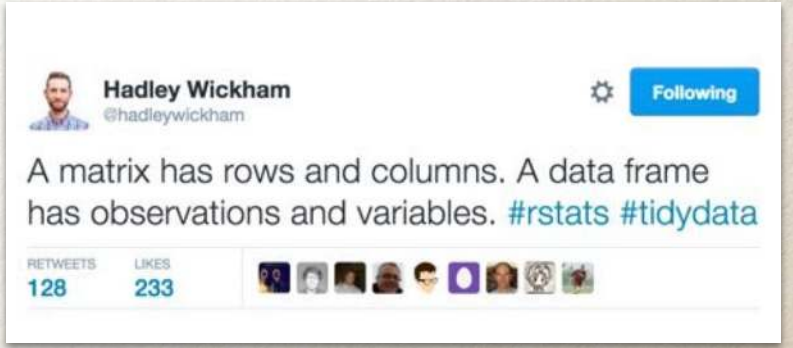

Otros tipos de Archivos

- Hojas de cálculo de Excel
- Archivos MATLAB
- Archivos SAS
- Archivos Stata
- Archivos HDF5
- Bases de Datos NoSQL
- Páginas web

Importing Excel spreadsheets

```
In [1]: import pandas as pd

In [2]: file = 'urbanpop.xlsx'

In [3]: data = pd.ExcelFile(file)

In [4]: print(data.sheet_names)
['1960-1966', '1967-1974', '1975-2011']

In [5]: df1 = data.parse('1960-1966')

In [6]: df2 = data.parse(0)
```

sheet name, as a string

sheet index, as a float

Leyendo archivos JSON

- **JSON = JavaScript Object Notation.**
- Se originó a partir de JavaScript pero ha trascendido sus orígenes para convertirse en un idioma independiente y ahora se reconoce como el estándar para el intercambio de datos.
- La popularidad de JSON se puede atribuir a la compatibilidad nativa del lenguaje JavaScript, lo que da como resultado un excelente rendimiento de análisis en los navegadores web.
- Además de eso, la sintaxis sencilla de JSON permite que tanto humanos como computadoras lean y escriban datos JSON sin esfuerzo.

Leyendo archivos JSON

JSON hello_frieda.json

```json
{
  "name": "Frieda",
  "isDog": true,
  "hobbies": ["eating", "sleeping", "barking"],
  "age": 8,
  "address": {
    "work": null,
    "home": ["Berlin", "Germany"]
  },
  "friends": [
    {
      "name": "Philipp",
      "hobbies": ["eating", "sleeping", "reading"]
    },
    {
      "name": "Mitch",
      "hobbies": ["running", "snacking"]
    }
  ]
}
```

- Un par clave-valor en un objeto JSON está separado por dos puntos (:).
- En el lado izquierdo de los dos puntos, se define una clave. Una clave es una cadena que debe encerrarse entre comillas dobles (").
- **A diferencia de Python, los strings en JSON no admiten comillas simples (').**

Leyendo archivos JSON

json.loads(...) **Analiza una cadena de datos JSON. Loads = abreviatura de load as string.**
Convierte: Objetos a diccionarios, matrices a listas, booleanos, enteros, pto flotantes y los strings se reconocen por lo que son y se convertirán en los tipos correctos en Python .Cualquier valor nulo se convertirá en el tipo *None* de Python

```
>>> import json

>>> jsonstring = '{"name": "erik", "age": 38, "married": true}'
>>> person = json.loads(jsonstring)
>>> print(person['name'], 'is', person['age'], 'years old')
erik is 38 years old
>>> print(person)
{'name': 'erik', 'age': 38, 'married': True}
```

The output might look like a string, but it's actually a dictionary that you can use in your code as explained on our page about Python dictionaries. You can check for yourself:

```
>>> type(person)
<class 'dict'>
```

JSON OBJECT	PYTHON OBJECT
object	dict
array	list
string	str
null	None
number (int)	int
number (real)	float
true	True
false	False

Creando archivos JSON

json.dumps() Codifica datos a formato JSON en Python.
Utilice json.dumps (abreviatura de 'dump to string') para convertir un objeto de Python que consta de diccionarios, listas y otros tipos nativos en una cadena:

```
import json

person = {'name': 'erik', 'age': 38, 'married': True}
json_string = json.dumps(person)
print(json_string)

# To make sure, let's print the type too
print(type(json_string))
```

Leyendo archivos JSON

json.dump() & json.load() **Permiten Codificar y Decodificar datos JSON en Python. Cargará datos o escribirá un archivo, pero debe abrirse el archivo primero**

```
data = {'name': 'Eric', 'age': 38 }

with open('data.json', 'w') as json_file:
    json.dump(data, json_file)
```

```
with open('data.json') as json_file:
    data = json.load(json_file)
    ...
```

Archivos HDF5

- **Formato de datos jerárquicos versión 5**
- **Estándar para almacenar grandes cantidades de datos numéricos**
- **Los conjuntos de datos pueden tener cientos de gigabytes o terabytes**
- **HDF5 puede escalar a exabytes**

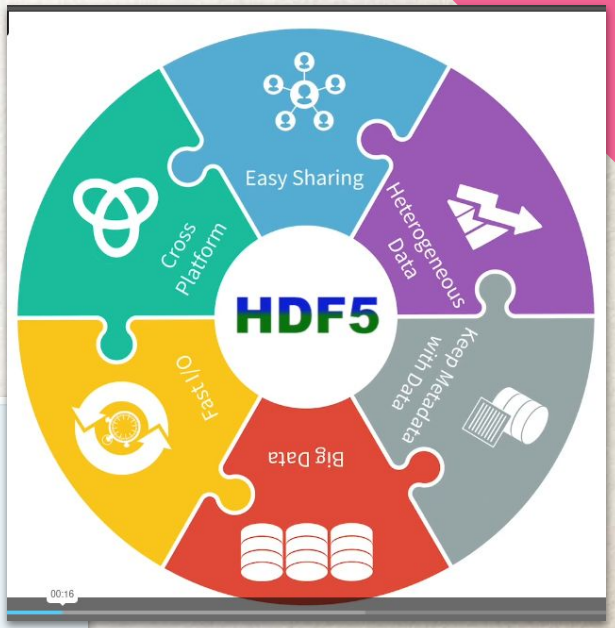


```
In [1]: import h5py

In [2]: filename = 'H-H1_LOSC_4_V1-815411200-4096.hdf5'

In [3]: data = h5py.File(filename, 'r') # 'r' is to read

In [4]: print(type(data))
<class 'h5py._hl.files.File'>
```

Bases de Datos Relacionales

Modelo relacional de “Ted” Codd

Conjunto de tablas interrelacionadas

- Orders table

OrderID	CustomerID	EmployeeID	OrderDate	RequiredDate	ShippedDate	ShipVia	Freight	ShipName	ShipAddress
10248	VINET	5	7/4/1996 12:00:00 AM	8/1/1996 12:00:00 AM	7/16/1996 12:00:00 AM	3	32.38	Vins et alcools Chevalier	59 rue de l'Abbaye
10251	VICTE	3	7/8/1996 12:00:00 AM	8/5/1996 12:00:00 AM	7/15/1996 12:00:00 AM	1	41.34	Victuailles en stock	2, rue du Commerce
10254	CHOPS	5	7/11/1996 12:00:00 AM	8/8/1996 12:00:00 AM	7/23/1996 12:00:00 AM	2	22.98	Chop-suey Chinese	Hauptstr. 31

- Customers table

CustomerID	CompanyName	ContactName	ContactTitle	Address	City	Region	PostalCode	Country
ALFKI	Alfreds Futterkiste	Maria Anders	Sales Representative	Obere Str. 57	Berlin	None	12209	Germany
AROUT	Around the Horn	Thomas Hardy	Sales Representative	120 Hanover Sq.	London	None	WA1 1DP	UK
BLAUS	Blauer See Delikatessen	Hanna Moos	Sales Representative	Forsterstr. 57	Mannheim	None	68306	Germany
BONAP	Bon app'	Laurence Lebihan	Owner	12, rue des Bouchers	Marseille	None	13008	France

- Employees table

EmployeeID	LastName	FirstName	Title	TitleOfCourtesy	BirthDate	HireDate	Address	City	Region
1	Davolio	Nancy	Sales Representative	Ms.	12/8/1948 12:00:00 AM	5/1/1992 12:00:00 AM	507 - 20th Ave. E.\r\nApt. 2A	Seattle	WA
2	Fuller	Andrew	Vice President, Sales	Dr.	2/19/1952 12:00:00 AM	8/14/1992 12:00:00 AM	908 W. Capital Way	Tacoma	WA
3	Leverling	Janet	Sales Representative	Ms.	8/30/1963 12:00:00 AM	4/1/1992 12:00:00 AM	722 Moss Bay Blvd.	Kirkland	WA

Modelo Relacional

- Ampliamente aceptado
- Las 13 Reglas de Codd
- Describe lo que es una Gestión de Bases de Datos Relacionales
- Reglas que el sistema debe cumplir para ser considerado relacional
- 5 Formas Normales

https://en.wikipedia.org/wiki/Codd%27s_12_rules

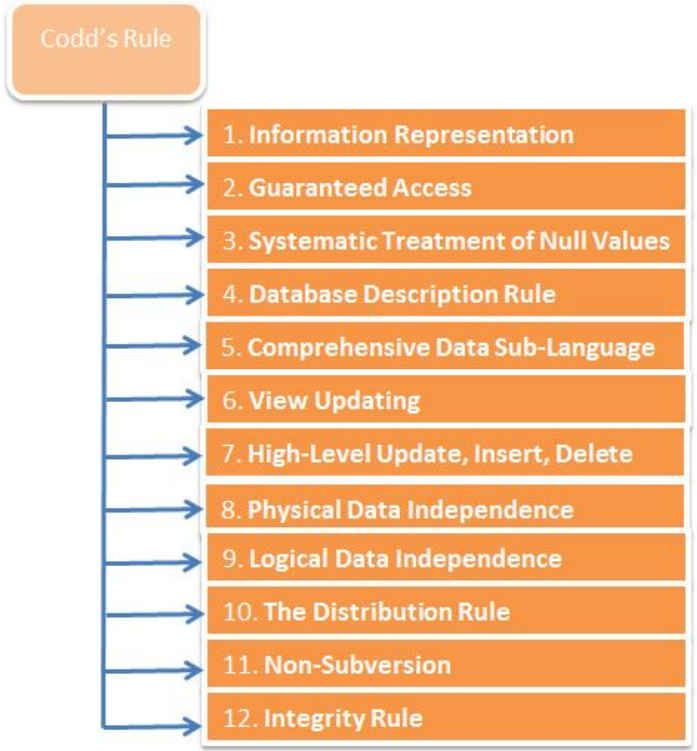

Sistemas de Bases de Datos

- PostgreSQL
- MySQL
- SQLite
- SQL = Structured Query Language

Python: SQLAlchemy

```
In [1]: from sqlalchemy import create_engine

In [2]: engine = create_engine('sqlite:///Northwind.sqlite')
```

```
In [3]: table_names = engine.table_names()

In [4]: print(table_names)
['Categories', 'Customers', 'EmployeeTerritories',
'Employees', 'Order Details', 'Orders', 'Products',
'Region', 'Shippers', 'Suppliers', 'Territories']
```

Flujo de trabajo de consultas SQL

1. Importar paquetes y funciones
2. Crear el motor de base de datos
3. Conéctese al motor
4. Consultar la base de datos
5. Guardar los resultados de la consulta en un DataFrame
6. Cierre la conexión

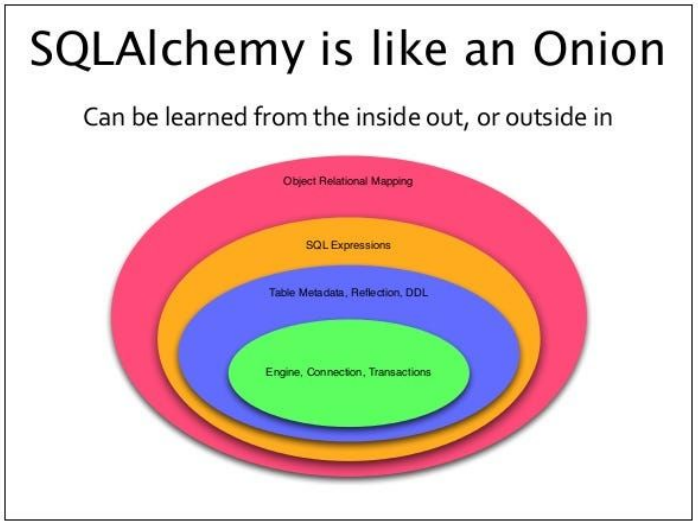

Consultando una base de datos

Usando el manejador de contexto

```
In [1]: from sqlalchemy import create_engine

In [2]: import pandas as pd

In [3]: engine = create_engine('sqlite:///Northwind.sqlite')

In [4]: with engine.connect() as con:
   ...:         rs = con.execute("SELECT OrderID, OrderDate,
ShipName FROM Orders")
   ...:         df = pd.DataFrame(rs.fetchmany(size=5))
   ...:         df.columns = rs.keys()
```

nro de filas que quiero

Resultados

```
In [5]: rs = con.execute("SELECT * FROM Orders")

In [6]: df = pd.DataFrame(rs.fetchall())

In [7]: con.close()
```

```
In [8]: print(df.head())
       0       1   2                          3                          4
0  10248   VINET   5   7/4/1996 12:00:00 AM   8/1/1996 12:00:00 AM
1  10251   VICTE   3   7/8/1996 12:00:00 AM   8/5/1996 12:00:00 AM
2  10254   CHOPS   5  7/11/1996 12:00:00 AM   8/8/1996 12:00:00 AM
3  10256   WELLI   3  7/15/1996 12:00:00 AM  8/12/1996 12:00:00 AM
4  10258   ERNSH   1  7/17/1996 12:00:00 AM  8/14/1996 12:00:00 AM
```

```
In [6]: df = pd.DataFrame(rs.fetchall())

In [7]: df.columns = rs.keys()
```

```
In [9]: print(df.head())
   OrderID CustomerID  EmployeeID              OrderDate
0    10248      VINET           5   7/4/1996 12:00:00 AM
1    10251      VICTE           3   7/8/1996 12:00:00 AM
2    10254      CHOPS           5  7/11/1996 12:00:00 AM
3    10256      WELLI           3  7/15/1996 12:00:00 AM
4    10258      ERNSH           1  7/17/1996 12:00:00 AM
```

Usando Pandas en la consulta

usando pandas_read_sql()

```
In [1]: from sqlalchemy import create_engine

In [2]: import pandas as pd

In [3]: engine = create_engine('sqlite:///Northwind.sqlite')

In [4]: with engine.connect() as con:
   ...:     rs = con.execute("SELECT * FROM Orders")
   ...:     df = pd.DataFrame(rs.fetchall())
   ...:     df.columns = rs.keys()
```

```
In [5]: df = pd.read_sql_query("SELECT * FROM Orders", engine)
```

Consultas Avanzadas

Las tablas estan ligadas por relaciones

- Orders table

OrderID	CustomerID	EmployeeID	OrderDate	RequiredDate	ShippedDate	ShipVia	Freight	ShipName	ShipAddress
10248	VINET	5	7/4/1996 12:00:00 AM	8/1/1996 12:00:00 AM	7/16/1996 12:00:00 AM	3	32.38	Vins et alcools Chevalier	59 rue de l'Abbaye
10251	VICTE	3	7/8/1996 12:00:00 AM	8/5/1996 12:00:00 AM	7/15/1996 12:00:00 AM	1	41.34	Victuailles en stock	2, rue du Commerce
10254	CHOPS	5	7/11/1996 12:00:00 AM	8/8/1996 12:00:00 AM	7/23/1996 12:00:00 AM	2	22.98	Chop-suey Chinese	Hauptstr. 31

- Customers table

CustomerID	CompanyName	ContactName	ContactTitle	Address	City	Region	PostalCode	Country
ALFKI	Alfreds Futterkiste	Maria Anders	Sales Representative	Obere Str. 57	Berlin	None	12209	Germany
AROUT	Around the Horn	Thomas Hardy	Sales Representative	120 Hanover Sq.	London	None	WA1 1DP	UK
BLAUS	Blauer See Delikatessen	Hanna Moos	Sales Representative	Forsterstr. 57	Mannheim	None	68306	Germany
BONAP	Bon app'	Laurence Lebihan	Owner	12, rue des Bouchers	Marseille	None	13008	France

- Employees table

EmployeeID	LastName	FirstName	Title	TitleOfCourtesy	BirthDate	HireDate	Address	City	Region
1	Davolio	Nancy	Sales Representative	Ms.	12/8/1948 12:00:00 AM	5/1/1992 12:00:00 AM	507 - 20th Ave. E.\r\nApt. 2A	Seattle	WA
2	Fuller	Andrew	Vice President, Sales	Dr.	2/19/1952 12:00:00 AM	8/14/1992 12:00:00 AM	908 W. Capital Way	Tacoma	WA
3	Leverling	Janet	Sales Representative	Ms.	8/30/1963 12:00:00 AM	4/1/1992 12:00:00 AM	722 Moss Bay Blvd.	Kirkland	WA

Consultas Avanzadas

Cruzando tablas: uso de JOIN

- Orders table

OrderID	CustomerID	EmployeeID	OrderDate	RequiredDate	ShippedDate	S
10248	VINET	5	7/4/1996 12:00:00 AM	8/1/1996 12:00:00 AM	7/16/1996 12:00:00 AM	3
10251	VICTE	3	7/8/1996 12:00:00 AM	8/5/1996 12:00:00 AM	7/15/1996 12:00:00 AM	1
10254	CHOPS	5	7/11/1996 12:00:00 AM	8/8/1996 12:00:00 AM	7/23/1996 12:00:00 AM	2

- Customers table

CustomerID	CompanyName	ContactName	ContactTitle	Address	Ci
ALFKI	Alfreds Futterkiste	Maria Anders	Sales Representative	Obere Str. 57	Be
AROUT	Around the Horn	Thomas Hardy	Sales Representative	120 Hanover Sq.	Lo
BLAUS	Blauer See Delikatessen	Hanna Moos	Sales Representative	Forsterstr. 57	M
BONAP	Bon app'	Laurence Lebihan	Owner	12, rue des Bouchers	M

```
In [1]: from sqlalchemy import create_engine

In [2]: import pandas as pd

In [3]: engine = create_engine('sqlite:///Northwind.sqlite')

In [4]: df = pd.read_sql_query("SELECT OrderID, CompanyName FROM
Orders INNER JOIN Customers on Orders.CustomerID =
Customers.CustomerID", engine)

In [5]: print(df.head())
   OrderID                CompanyName
0    10248  Vins et alcools Chevalier
1    10251       Victuailles en stock
2    10254          Chop-suey Chinese
3    10256     Wellington Importadora
4    10258                Ernst Handel
```

Importando archivos de la Web

urllib vs requests

```
In [1]: from urllib.request import urlretrieve

In [2]: url = 'http://archive.ics.uci.edu/ml/machine-learning-
databases/wine-quality/winequality-white.csv'

In [3]: urlretrieve(url, 'winequality-white.csv')
Out[3]: ('winequality-white.csv', <http.client.HTTPMessage at
0x103cf1128>)
```

GET requests using urllib

```
In [1]: from urllib.request import urlopen, Request

In [2]: url = "https://www.wikipedia.org/"

In [3]: request = Request(url)

In [4]: response = urlopen(request)

In [5]: html = response.read()

In [6]: response.close()
```

Importando archivos de la Web

urllib

Para recuperar un recurso a través de una URL y almacenarlo en una ubicación temporal, puede hacerlo a través de **shutil.copyfileobj()** y **tempfile**. Funciones de **NamedTemporaryFile():**

```
import shutil
import tempfile
import urllib.request

with urllib.request.urlopen('http://python.org/') as response:
    with tempfile.NamedTemporaryFile(delete=False) as tmp_file:
        shutil.copyfileobj(response, tmp_file)

with open(tmp_file.name) as html:
    pass
```

Python requests

requests package

GET requests using requests

- One of the most downloaded Python packages

```
In [1]: import requests

In [2]: url = "https://www.wikipedia.org/"

In [3]: r = requests.get(url)

In [4]: text = r.text
```

Acondicionamiento de Datos

- Puede consumir hasta el 90% del tiempo del proyecto
- Los datos casi nunca vienen limpios
- Como hacer Diagnosis de los Datasets

Problemas comunes

- Nombres de columnas inconsistentes
- Datos faltantes
- Valores atípicos
- Filas duplicadas
- Desordenado
- Necesidad de procesar columnas
- Los tipos de columnas pueden indicar valores de datos inesperados

Datos: Un Recurso Natural

Los datos como recurso natural Al igual que el petróleo, el gas y otros recursos naturales, la extracción de datos requiere habilidad y energía. De hecho, ya consume ~10% de la electricidad a nivel mundial. A medida que se afianza la frontera digital, necesitamos abordar mejor la forma en que tratamos los datos para mitigar el crecimiento de los llamados vertederos de datos.

Antonio Neri

President and Chief Executive Officer, Hewlett Packard Enterprise

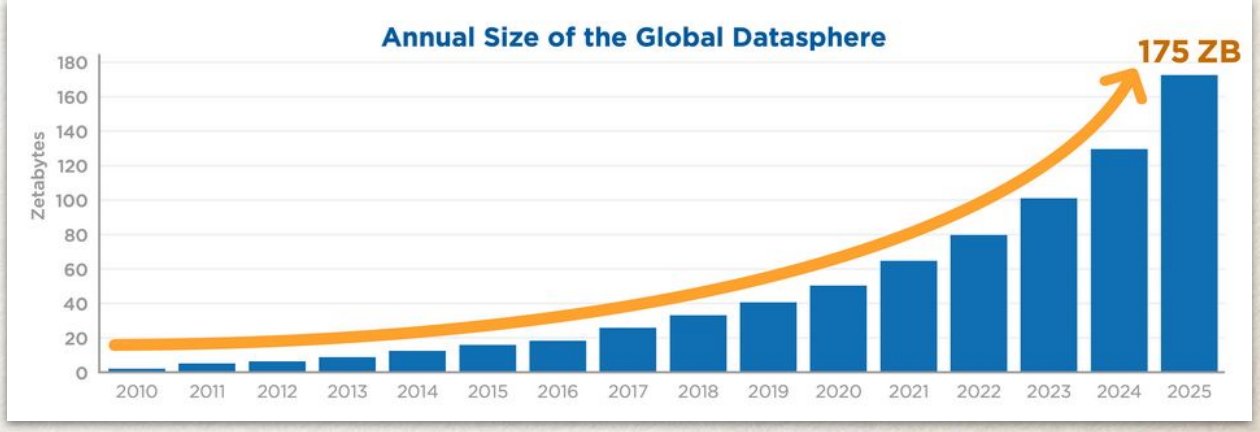

https://www.weforum.org/stories/2020/03/we-should-treat-data-as-a-natural-resource-heres-why/

Datos Estructurados vs No Estructurados

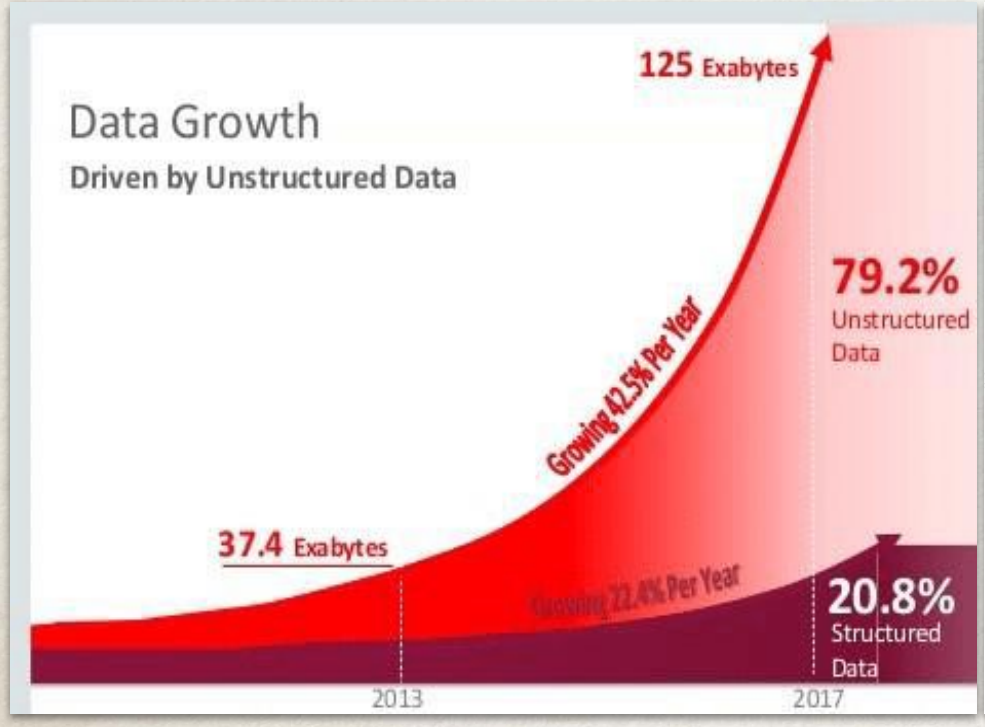

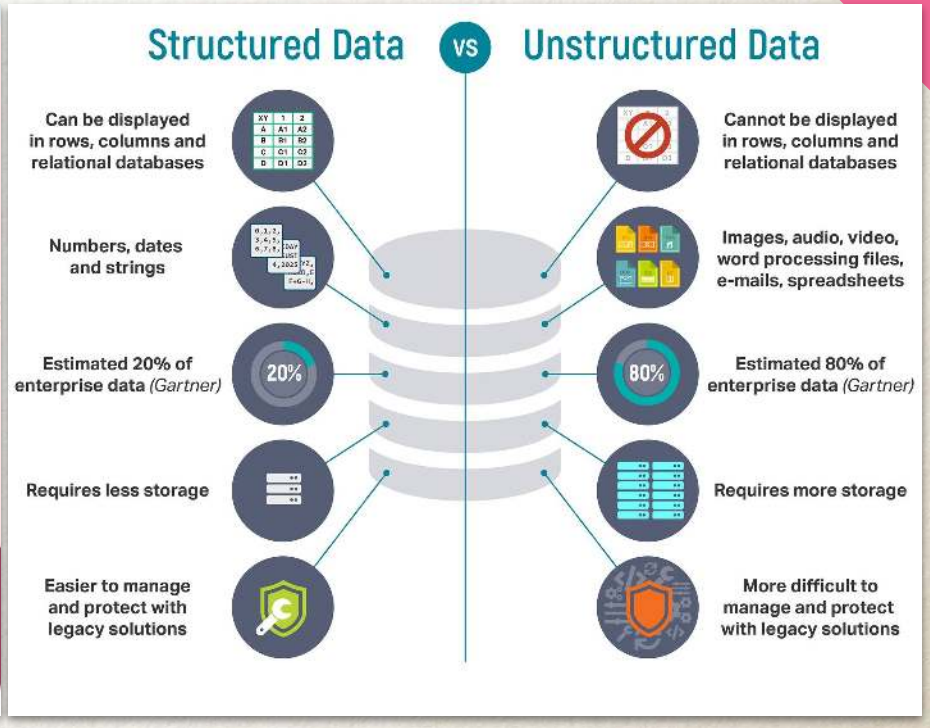

Prácticas útiles para acondicionar Datos

- Análisis Exploratorio de Datos
- Reemplazar valores y/o cadenas de caracteres
- Cambio de tipo de datos
- Imputación de datos faltantes
- Pivoteo de tablas

Análisis Exploratorio de Datos

Con Pandas y Numpy

Importé mis datos: Y ahora qué?

Necesito saber como es el estado de estos datos:

- Están en un formato adecuado ?
- Los tipos de datos son correctos o hay que cambiarlos?
- Hay datos faltantes? Cuantos?, Qué hacemos con estos?
- Hay valores extremos/erróneos que debamos corregir?
- Qué hacer con los datos categóricos?
- Como puedo obtener una vista general de los datos?

Datos desordenados

Messy Data

	Continent	Country	female literacy	fertility	population
0	ASI	Chine	90.5	1.769	1.324655e+09
1	ASI	Inde	50.8	2.682	1.139965e+09
2	NAM	USA	99.0	2.077	3.040600e+08
3	ASI	Indonésie	88.8	2.132	2.273451e+08
4	LAT	Brésil	90.2	1.827	NaN

- Nombres de columna inconsistentes
- Datos Faltantes
- Nombres de país en Francés

```
In [1]: import pandas as pd
In [2]: df = pd.read_csv('literary_birth_rate.csv')
```

Archivo *'literary_birth_rate.csv'* en el repo de GitHub dentro de /datasets
bajarlo con urllib primero!

h!p://www.eea.europa.eu/data-and-maps/figures/correlation-between-fertility-and-female-education

Inspección Visual

head() & tail()

```
In [3]: df.head()
Out[3]:
 Continent    Country   female literacy  fertility   population
0       ASI       Chine             90.5      1.769  1.324655e+09
1       ASI        Inde             50.8      2.682  1.139965e+09
2       NAM         USA             99.0      2.077  3.040600e+08
3       ASI   Indonésie             88.8      2.132  2.273451e+08
4       LAT      Brésil             90.2      1.827           NaN

In [4]: df.tail()
Out[4]:
 Continent          Country      female literacy  fertility    population
0        AF  Sao Tomé-et-Principe             90.5      1.769  1.324655e+09
1       LAT                 Aruba             50.8      2.682  1.139965e+09
2       ASI                 Tonga             99.0      2.077  3.040600e+08
3       OCE             Australia             88.8      2.132  2.273451e+08
4       OCE                Sweden             90.2      1.827           NaN
```

Inspección Visual

```
In [5]: df.columns
Out[5]: Index(['Continent', 'Country ', 'female literacy',
'fertility', 'population'], dtype='object')

In [6]: df.shape
Out[6]: (164, 5)

In [7]: df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 164 entries, 0 to 163
Data columns (total 5 columns):
Continent           164 non-null object
Country             164 non-null object
female literacy     164 non-null float64
fertility           164 non-null object
population          122 non-null float64
dtypes float64(2), object(3)
memory usage: 6.5+ KB
```

tipo de cada columna

```
In [1]: df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 164 entries, 0 to 163
Data columns (total 5 columns):
continent           164 non-null object
country             164 non-null object
female literacy     164 non-null float64
fertility           164 non-null object
population          122 non-null float64
dtypes float64(2), object(3)
memory usage: 6.5+ KB
```

Frecuencia de valores

```
In [2]: df.continent.value_counts(dropna=False)
Out[2]:
AF     49
ASI    47
EUR    36
LAT    24
OCE     6
NAM     2
Name:  continent, dtype: int64
```

df['continent'].value_counts(dropna=False)
da lo mismo

```
In [4]: df.country.value_counts(dropna=False).head()
Out[4]:
Sweden      2
Algerie     1
Germany     1
Angola      1
Indonésie   1
Name: country, dtype: int64
```

chaining = concatenación de Métodos

Estadísticas generales

```
In [7]: df.describe()
Out[7]:
       female_literacy    population
count       164.000000  1.220000e+02
mean         80.301220  6.345768e+07
std          22.977265  2.605977e+08
min          12.600000  1.035660e+05
25%          66.675000  3.778175e+06
50%          90.200000  9.995450e+06
75%          98.500000  2.642217e+07
max         100.000000  2.313000e+09
```

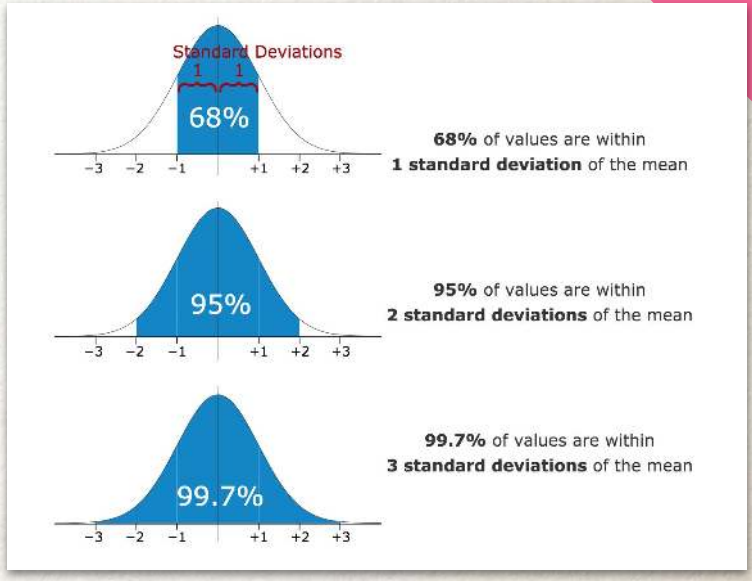

Gráficos Generales

Histogramas: Distribución continua de datos

```python
import matplotlib.pyplot as plt
import numpy as np

# Generate random data for the histogram
data = np.random.randn(1000)

# Plotting a basic histogram
plt.hist(data, bins=30, color='skyblue', edgecolor='black')

# Adding labels and title
plt.xlabel('Values')
plt.ylabel('Frequency')
plt.title('Basic Histogram')

# Display the plot
plt.show()
```

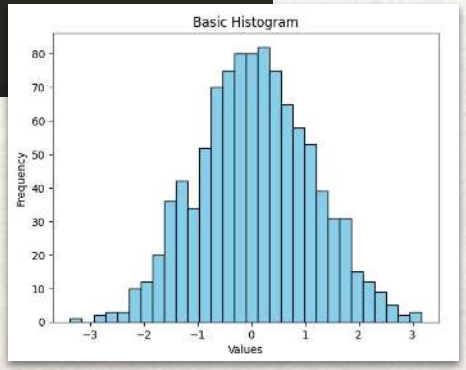

Bar plot: Datos discretos o categóricos

```python
import matplotlib.pyplot as plt
import numpy as np

fruits = ['Apples', 'Bananas', 'Cherries', 'Dates']
sales = [400, 350, 300, 450]

plt.bar(fruits, sales)
plt.title('Fruit Sales')
plt.xlabel('Fruits')
plt.ylabe
plt.show(
```

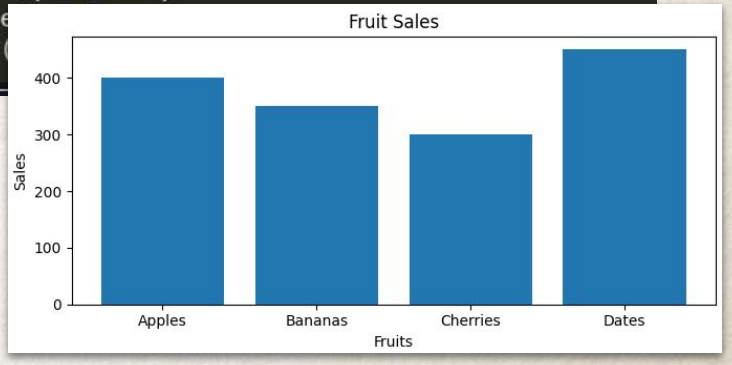

Box Plot vs Scatter Plot

```python
# Import libraries
import matplotlib.pyplot as plt
import numpy as np


# Creating dataset
np.random.seed(10)

data_1 = np.random.normal(100, 10, 200)
data_2 = np.random.normal(90, 20, 200)
data_3 = np.random.normal(80, 30, 200)
data_4 = np.random.normal(70, 40, 200)
data = [data_1, data_2, data_3, data_4]

fig = plt.figure(figsize =(10, 7))

# Creating axes instance
ax = fig.add_axes([0, 0, 1, 1])

# Creating plot
bp = ax.boxplot(data)

# show plot
plt.show()
```

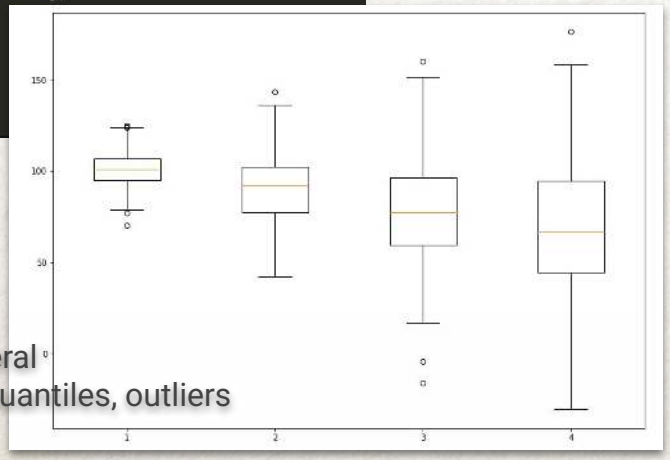

Estadística general
25%, 50%, 75% cuantiles, outliers

```python
import matplotlib.pyplot as plt
import numpy as np

# Fixing random state for reproducibility
np.random.seed(19680801)


N = 50
x = np.random.rand(N)
y = np.random.rand(N)
colors = np.random.rand(N)
area = (30 * np.random.rand(N))**2  # 0 to 15 point radii

plt.scatter(x, y, s=area, c=colors, alpha=0.5)
plt.show()
```

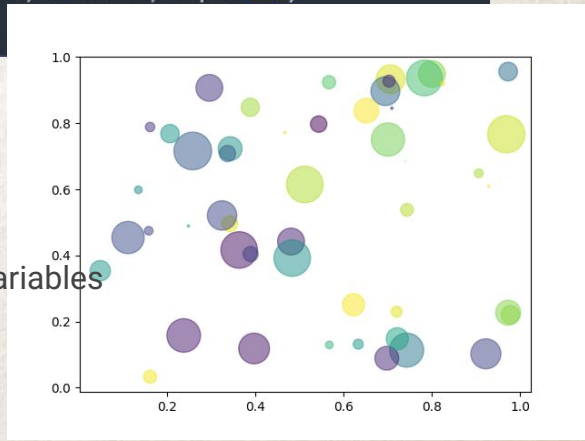

Relación entre variables

Box-Plots

Distribución e identificación de valores extremos

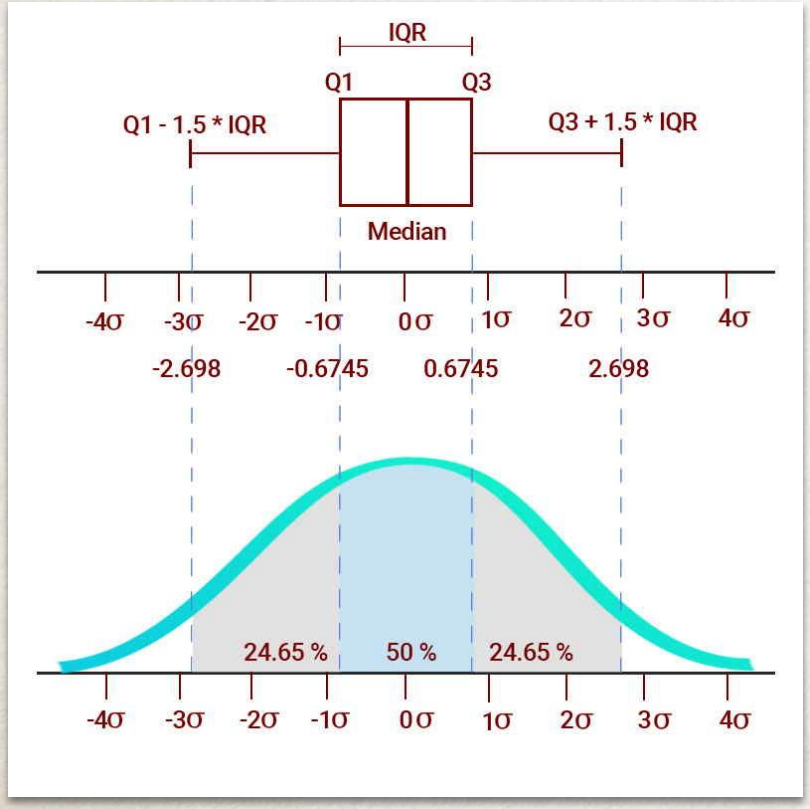

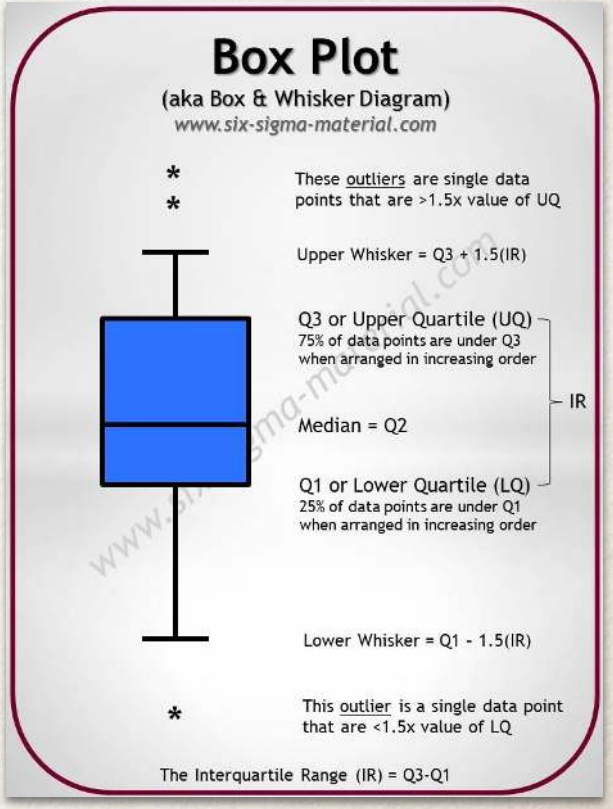

Inspección Visual

Python missingno

```
# Program to visualize missing values in dataset

# Importing the libraries
import pandas as pd
import missingno as msno

# Loading the dataset
df = pd.read_csv("kamyr-digester.csv")

# Visualize missing values as a matrix
msno.matrix(df)
```

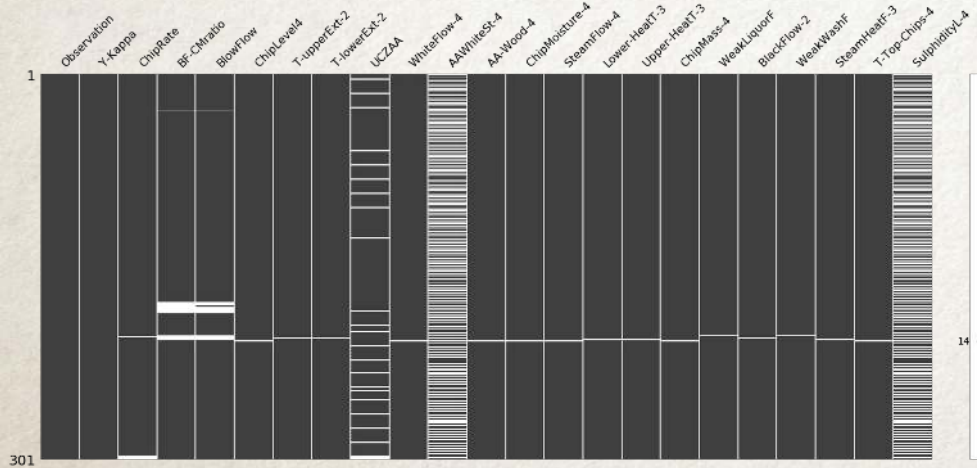


```
# Program to visualize missing values in dataset

# Importing the libraries
import pandas as pd
import missingno as msno

# Loading the dataset
df = pd.read_csv("kamyr-digester.csv")


# Visualize the correlation between the number of
# missing values in different columns as a heatmap
msno.heatmap(df)
```

Correlación entre valores perdidos en cada variable

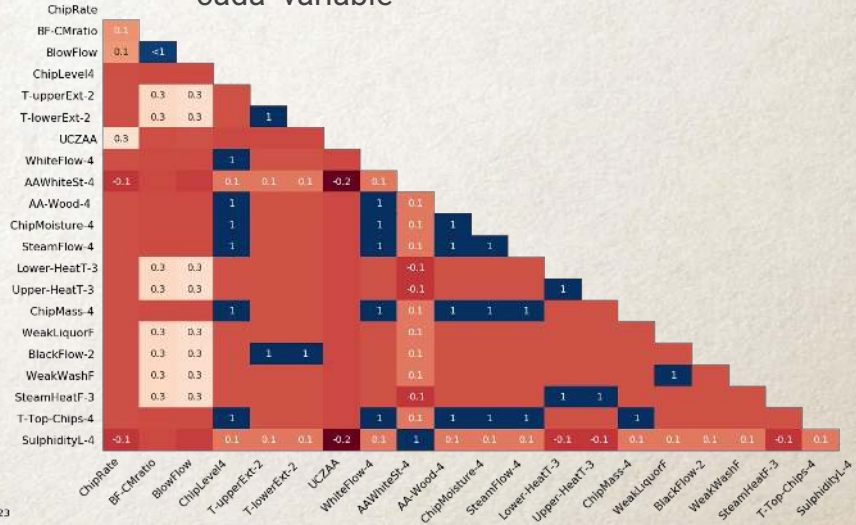

Inspección Visual

Correlación

$$r = \frac{cov(X, Y)}{\sigma_X \sigma_Y}$$

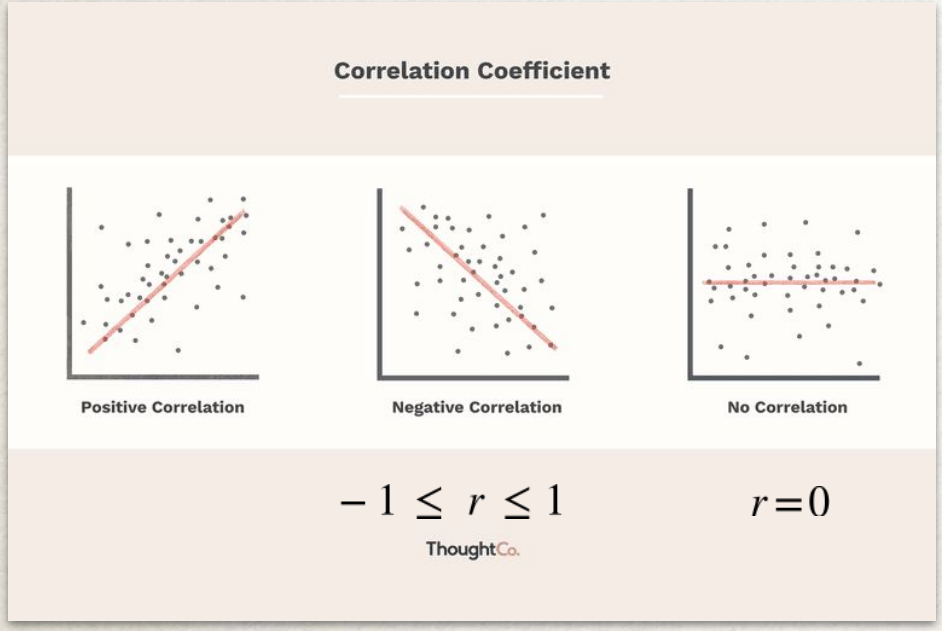

Correlación plot en Missingno:

- r~ -1: ⇒ si aparece una variable, es muy probable que falte la otra.
- r ~ 0: ⇒ no hay dependencia entre la aparición de valores faltantes de dos variables.
- r ~ 1: ⇒ si aparece una variable, es muy probable que la otra variable esté presente.

Obs: La existencia de correlación no implica necesariamente relación de causa-efecto entre variables.
También pueden haber relaciones fortuitas entre variables: Ej. máximos solares y guerras

Datos Faltantes y Duplicados

Método drop_duplicates()

	name	sex	treatment a	treatment b
0	Daniel	male	-	42
1	John	male	12	31
2	Jane	female	24	27
3	Daniel	male	-	42

```
In [1]: df = df.drop_duplicates()

In [2]: print(df)
     name     sex treatment a  treatment b
0  Daniel    male           -           42
1    John    male          12           31
2    Jane  female          24           27
```

Datos Faltantes y Duplicados

Estrategias para datos faltantes

¿Que hago con los datos faltantes o erróneos?

- Remoción : método **.dropna()**
- Imputación: método .**fillna()**
  Reemplazo por: media general
  ` media de los vecinos próximos
  interpolacion
  valor predefinido
  etc.

```
tips_dropped = tips_nan.dropna()
```

```
In [6]: tips_nan['sex'] = tips_nan['sex'].fillna('missing')
```

Conversiones de Tipo

```
In [2]: df['treatment b'] = df['treatment b'].astype(str)

In [3]: df['sex'] = df['sex'].astype('category')

In [4]: df.dtypes
Out[4]:
name              object
sex             category
treatment a       object
treatment b       object
dtype: object
```

```
col_names=['Datetime','gic', 'T1','T2'];

missing_vals = ["NaN", "NO DATA"]

files = glob.glob("gic_qrp*.csv")

df = pd.DataFrame([], columns=col_names)

for file in files:
    raw = pd.read_csv(file,
                header = None,
                skiprows = 1,
                usecols = [0,1,2,3],
                parse_dates = [0],
                na_values = missing_vals,
                names = col_names);
    df = pd.concat([df, raw], ignore_index=True)


convert_dict = {'Datetime': 'datetime64[ns]',
                'gic': float,
                'T1' : float,
                'T2' : float}

df = df.astype(convert_dict);
```

Cadenas de caracteres

Paquete re

- Gran parte de la limpieza de datos implica la manipulación de cadenas de caracteres
- La mayoría de los datos del mundo son texto no estructurado
- Manipulación de cadenas para hacer conjuntos de datos coherentes entre sí

```
In [1]: import re

In [2]: pattern = re.compile('\$\d*\.\d{2}')

In [3]: result = pattern.match('$17.89')

In [4]: bool(result)
True
```

Uso de expresiones regulares

- Compilar el patrón
- Utilice el patrón compilado para hacer coincidir los valores,
- Esto nos permite usar el patron una y otra vez
- Útil ya que queremos hacer coincidir los valores a lo largo de una columna de valores

https://docs.python.org/3/library/re.html#

Cadenas de caracteres

Método replace()

El método **replace()** devuelve una nueva cadena con algunos caracteres de la cadena original reemplazados. La cadena original no se ve afectada ni modificada.

string.replace(old_char, new_char, count)

```
str = "I love JavaScript. I prefer JavaScript to Python because JavaScript looks mo

new_str = str.replace("JavaScript", "PHP")

print(new_str)
# I love PHP. I prefer PHP to Python because PHP looks more beautiful
```

old_char: cadena original
new_char: cadena nueva
count: max. nro de cambios, (todos por defecto)

```
s = 'one two one two one'
# reemplazo todas las ocurrencias)
print(s.replace('one', 'XXX')) (
# XXX two XXX two XXX
# reemplazo solo en 2 ocurrencias
print(s.replace('one', 'XXX', 2))
# XXX two XXX two one
```

Cadenas de caracteres

Métodos .translate(), re.sub() & re.subn()

Utilice el método **translate()** para reemplazar varios caracteres diferentes. Puedes crear la tabla de traducción necesaria para **translate()** usando **str.maketrans()**.

```
s = 'one two one two one'

print(s.translate(str.maketrans({'o': 'O', 't': 'T'})))
# One TwO One TwO One

print(s.translate(str.maketrans({'o': 'XXX', 't': None})))
# XXXne wXXX XXXne wXXX XXXne
```

También se puede usar **re.sub() & re.subn(),** la url abajo ofrece varios ejemplos

https://note.nkmk.me/en/python-str-replace-translate-re-sub/

Formateo & Conversión de Fechas

Paquete `datetime`

Parsing: Convertir un string en un objeto tipo datetime: `strptime()`

```
>>> from datetime import datetime
>>> datetime.strptime("2020-01-01 14:00", "%Y-%m-%d %H:%M")
datetime.datetime(2020, 1, 1, 14, 0)
```

Formating: Convertir un objeto tipo datetime en un string : `strftime()`

```
>>> from datetime import datetime
>>> date = datetime.strptime("2020-01-01 14:00", "%Y-%m-%d %H:%M")
>>> datetime.strftime(date, "%a %B %d, %Y %I:%M %p")
'Wed January 01, 2020 02:00 PM'
```

Códigos de Conversión de Fechas

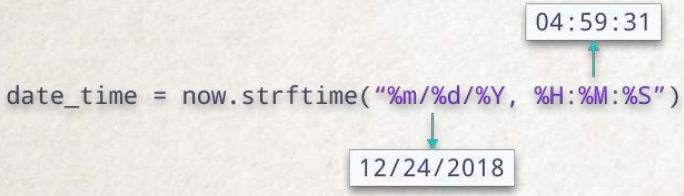

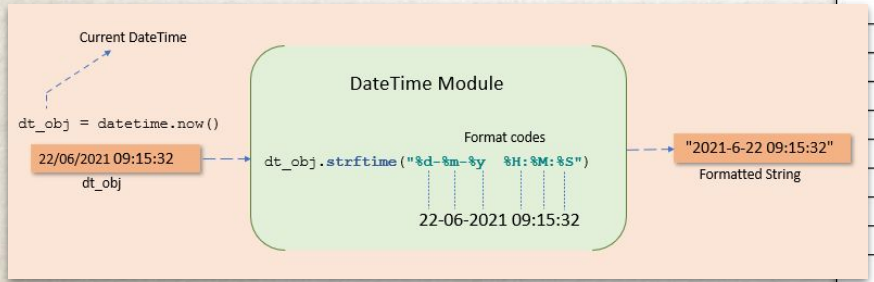

Directive	Description	Example
%a	Weekday, short version	Wed
%A	Weekday, full version	Wednesday
%w	Weekday as a number 0-6, 0 is Sunday	3
%d	Day of month 01-31	31
%b	Month name, short version	Dec
%B	Month name, full version	December
%m	Month as a number 01-12	12
%y	Year, short version, without century	18
%Y	Year, full version	2018
%H	Hour 00-23	17
%I	Hour 00-12	5
%p	AM/PM	PM
%M	Minute 00-59	41
%S	Second 00-59	8
%f	Microsecond 000000-999999	548513
%z	UTC offset	100
%Z	Timezone	CST
%j	Day number of year 001-366	365
%U	Week number of year, Sunday as the first day of week, 00-53	52
%W	Week number of year, Monday as the first day of week, 00-53	52
%c	Local version of date and time	Mon Dec 31 17:41:00 2018
%C	Century	20
%x	Local version of date	12/31/18
%X	Local version of time	17.41.00
%%	A % character	%
%G	ISO 8601 year	2018
%u	ISO 8601 weekday (1-7)	1
%V	ISO 8601 weeknumber (01-53)	1

Operaciones con Fechas

```
>>> from datetime import datetime, timedelta
>>> date = datetime.now()
>>> date
datetime.datetime(2020, 2, 6, 14, 49, 14, 277747)
>>> date - timedelta(minutes=10)
datetime.datetime(2020, 2, 6, 14, 39, 14, 277747)
>>> date - timedelta(hours=10)
datetime.datetime(2020, 2, 6, 4, 49, 14, 277747)
>>> date - timedelta(days=10)
datetime.datetime(2020, 1, 27, 14, 49, 14, 277747)
```

.timedelta()
Adiciona un corrimiento temporal

En Pandas puedo crear un rango de fechas

indx = **pd.date_range**('2021-01-01 00:00:00', '2021-07-31-23:59:00', freq='min')

Tidy Data

Concepto de Datos Ordenados (Hadley Wickham, 2014)

¿Por que los datos tienen que estar ordenados?:

1. **Hay una ventaja general al elegir una forma coherente de almacenar datos. Si tiene una estructura de datos coherente, es más fácil aprender las herramientas que funcionan con ella porque tienen una uniformidad subyacente. Algunas herramientas, por ejemplo, el paquete de visualización de datos seaborn, están diseñadas teniendo en cuenta los datos ordenados.**
2. **Hay una ventaja específica en la colocación de variables en columnas, ya que le permite aprovechar las operaciones vectorizadas de pandas.**

Los datos ordenados no van a ser apropiados siempre, pero son un valor predeterminado muy bueno para los datos tabulares. Una vez que lo use como predeterminado, es más fácil pensar en cómo realizar las operaciones posteriores.

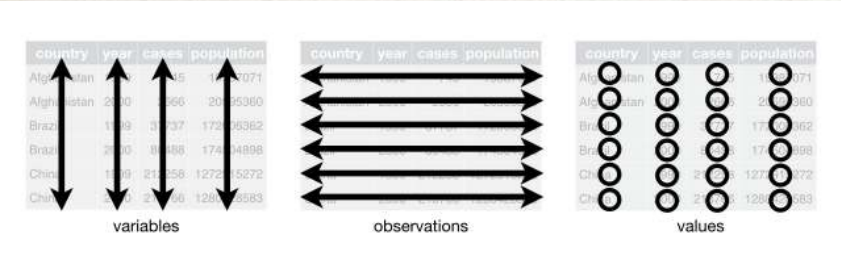

formato ancho (messy)

id	bp1	bp2
A	100	120
B	140	115
C	120	125

formato largo, (tidy)

id	measurement	value
A	bp1	100
A	bp2	120
B	bp1	140
B	bp2	115
C	bp1	120
C	bp2	125

Melt vs Pivot

	name	treatment a	treatment b
0	Daniel	-	42
1	John	12	31
2	Jane	24	27

	name	treatment	value
0	Daniel	treatment a	-
1	John	treatment a	12
2	Jane	treatment a	24
3	Daniel	treatment b	42
4	John	treatment b	31
5	Jane	treatment b	27

Dos problemas comunes que se encuentran en los datos que se ingieren y que hacen que estén desordenados:

- **Una variable puede estar distribuida en varias columnas.**
- **Una observación puede estar dispersa en varias filas.**

Para el primero, debemos "fundir", (**melt**) los datos anchos, con múltiples columnas, en datos largos.
Para el último, necesitamos desapilar o **pivotar** las múltiples filas en columnas (es decir, ir de largo a ancho).

```
In [2]: pd.melt(frame=df, id_vars='name',
   ...:         value_vars=['treatment a', 'treatment b'],
   ...:         var_name='treatment', value_name='result')
Out[2]:
    name     treatment  result
0  Daniel  treatment a       -
1    John  treatment a      12
2    Jane  treatment a      24
3  Daniel  treatment b      42
4    John  treatment b      31
5    Jane  treatment b      27
```

```
In [5]: weather2_tidy = weather.pivot_table(values='value',
   ...:                                     index='date',
   ...:                                     columns='element',
   ...:                                     aggfunc=np.mean)
Out[5]:
element      tmax tmin
date
2010-01-30   27.8 14.5
2010-02-02   27.3 15.4
```

Mejor para reporting vs mejor para análisis

Obs: En algunas operaciones el formato tidy no es adecuado, p. ej. diferenciación en series temporales

Sumario

- La limpieza de datos involucra combinar una gran cantidad de habilidades
- En general es necesario combinar datos de diversas fuentes
- No es posible implementar un algoritmo exitoso de ML con datos malos
- Python ofrece una gran variedad de paquetes y métodos para resolver la mayoría de de los problemas comunes en los datos de trabajo
- Aun así, hay problemas difíciles de abordar y que requieren del expertise del operador
- El Tidy Data es muy útil a la hora de normalizar datos y realizar análisis pero no muy adecuado para realizar reportes y visualización

Python: